

企业财务数据分析

01

数据特征分析与连接

描述性统计分析

在财务工作中，常常需要计算各种财务指标的合计数、平均值、最大最小值、标准差等，那么如何才能快速知道这些统计值呢？

函数	描述	函数	描述	函数	描述
<u>count()</u>	非空值的个数	<u>median()</u>	中位数	<u>mad()</u>	平均绝对偏差
<u>sum()</u>	求和	<u>mode()</u>	众数	<u>abs()</u>	绝对值
<u>mean()</u>	平均值	<u>prod()</u>	数组元素乘积	<u>cov()</u>	协方差
<u>min()</u>	最小值	<u>quantile()</u>	分位数	<u>corr()</u>	相关系数
<u>max()</u>	最大值	<u>var()</u>	样本方差	<u>pct_change()</u>	百分数变化
<u>describe()</u>	统计信息摘要	<u>std()</u>	样本标准差	<u>diff()</u>	一阶差分

Pandas中常用统计函数

describe函数

describe()函数：用于生成描述性统计信息，将所有数值列进行统计，返回DataFrame中常见的统计指标，包括值个数、均值、标准差、最大最小值、百分数。

语法：DataFrame.describe(percentiles=None, include=None, exclude=None, datetime_is_numeric=False)

常用参数	说明
percentiles	百分位数，介于 0-1 之间，默认[25%, 50%, 75%]
include	包含在结果中的数据类型，默认所有数值列
exclude	排除在结果中的数据类型，默认不排除任何内容
<u>datetime_is_numeric</u>	是否将 datetime <u>dtypes</u> 视为数字，默认为 False

describe()函数常用参数

describe函数

例3-4-1：读取data.xlsx中利润表项目数据，并使用describe()函数分析数据。

URL地址：<https://keyun-oss.acctedu.com/app/bigdata/basics/data.xlsx>

```
# 引入pandas
import pandas as pd

# 读取data.xlsx利润表项目前5行
df=pd.read_excel(r'https://keyun-oss.acctedu.com/app/bigdata/basics/data.xlsx',sheet_name=1,converters={'年':str,'月':str})
df.describe()
```

运行结果:



	营业收入	营业成本	净利润
count	24.000000	24.000000	24.000000
mean	337040.000000	210628.488333	63897.880000
std	45327.390222	30427.162225	10580.68317
min	248850.000000	155630.790000	45912.830000
25%	308675.000000	191006.562500	55033.370000
50%	325900.000000	205720.200000	63383.140000
75%	375275.000000	233922.550000	70726.815000
max	424000.000000	266484.000000	87133.200000

pct_change()函数

pct_change()函数：返回当前元素与先前元素之间的百分比变化，默认计算与前一行的百分比变化，适用于财务报表的环比分析。

语法：DataFrame.pct_change(periods=1, fill_method='pad', limit=None,freq=None, **kwargs)

常用参数	说明
periods	计算周期，默认为 1
fill_method	填充空值的方法，默认'pad'，表示用前一个非缺失值填充，bfill用后一个非缺失值填充，None 不填充
limit	限制填充次数
axis	计算方向，{0 或'index'， 1 或'columns'}，默认 axis=0

pct_change()函数常用参数

例3-4-2：以例3-4-1读取的df，计算营业收入、营业成本、净利润的环比增长率。

```
# 计算环比增长率
df.set_index(['年','月']).pct_change().head()
```

		营业收入	营业成本	净利润
年 月				
2019	1	NaN	NaN	NaN
	2	0.201895	0.207758	0.158439
	3	-0.245452	-0.236417	-0.284614
	4	0.146916	0.164521	0.140699
	5	0.031849	-0.049399	0.283766

累计统计

提示

axis=0: 默认值, 沿0轴计算, 即计算每列的值。
axis=1: 沿1轴计算, 即计算每行的值。

累计统计常用函数

函数	描述
<code>cumsum()</code>	累计总和
<code>cumprod()</code>	累计乘积
<code>cummax()</code>	累计最大值
<code>cummin()</code>	累计最小值

例

例3-4-3以例3-4-1读取的df, 计算2019年各月” 营业收入、营业成本、净利润” 的本年累计金额。

代码

```
# 累计统计
df.loc[df['年']=='2019'].set_index(['年','月']).cumsum().head()
```

		营业收入	营业成本	净利润
年	月			
2019	1	274400	168756.00	55401.36
	2	604200	372572.40	119580.44
	3	853050	528203.19	165493.27
	4	1138460	709438.54	217866.01
	5	1432960	881721.04	285100.36

运行结果

数据排序-sort_values()函数

sort_values()函数：按照某行或某列的值进行升序或降序排序

语法：DataFrame.sort_values(by, axis=0, ascending=True, inplace=False, kind='quicksort', na_position='last', ignore_index=False, key=None)

常用参数	描述
by	axis 轴上的某个索引或索引列表，按什么排序
axis	要排序的轴，{0 或 'index', 1 或 'columns'}，默认 0，按照指定列数据排序
ascending	排序方式，默认为 True，代表升序排序，False 代表降序排序
<u>inplace</u>	默认为 False，True 表示直接在原数据上排序
<u>ignore_index</u>	是否重建索引，默认为 False

sort_values()函数常用参数

例3-4-4要求：按照净利润降序排序，显示前5行。

数据排序

df.sort_values('净利润', ascending=False).head()

	年	月	营业收入	营业成本	净利润
16	2020	5	322000	175329.0	87133.20
19	2020	8	424000	266484.0	79076.00
20	2020	9	392000	240884.0	78282.40
17	2020	6	384200	237627.7	75264.78
13	2020	2	388000	243664.0	74108.00

数据排序-sort_index()函数

sort_index()函数：在指定轴上根据索引值对数据进行排序，默认使用行索引升序排序。

语法：DataFrame.sort_index(axis = 0, level = None, ascending = True, inplace = False, kind = 'quicksort', na_position = 'last', sort_remaining = True, ignore_index = False, key = None)

例3-4-5：按行索引降序排序，显示前5行。

按照行索引降序排序

df.sort_index(ascending=False).head()

运行结果：



	年	月	营业收入	营业成本	净利润
23	2020	12	401200	264069.84	62587.20
22	2020	11	343500	221557.50	59391.15
21	2020	10	354820	220839.97	69012.49
20	2020	9	392000	240884.00	78282.40
19	2020	8	424000	266484.00	79076.00

描述性统计分析小结

- 描述性统计分析:sum、count、mean、min、max、describe、pct_change
- 累计统计:cumsum、cumprod、cummax、cummin
- 数据排序:sort_values、sort_index